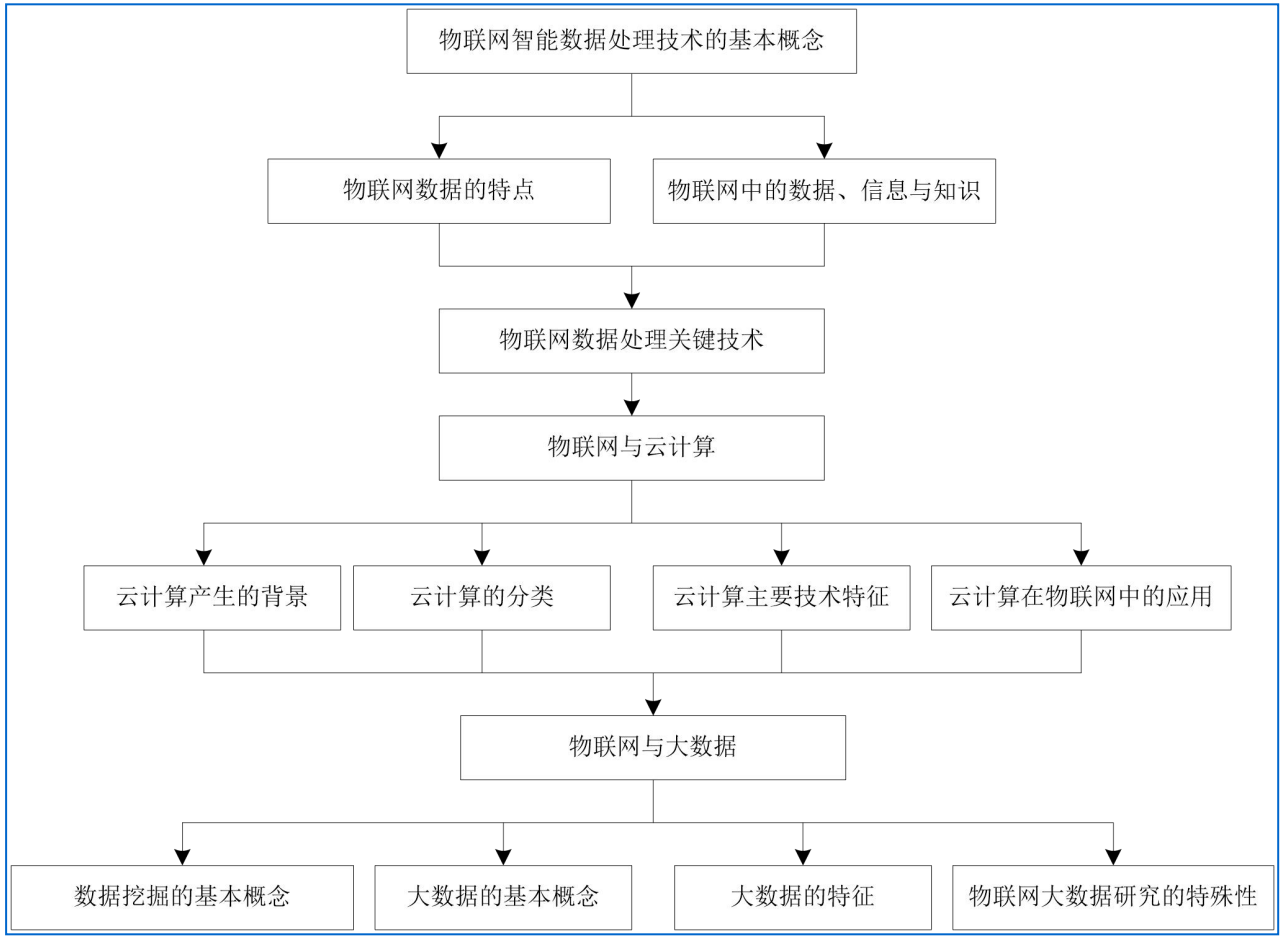


第7章 智能数据处理与大数据

本章知识点结构

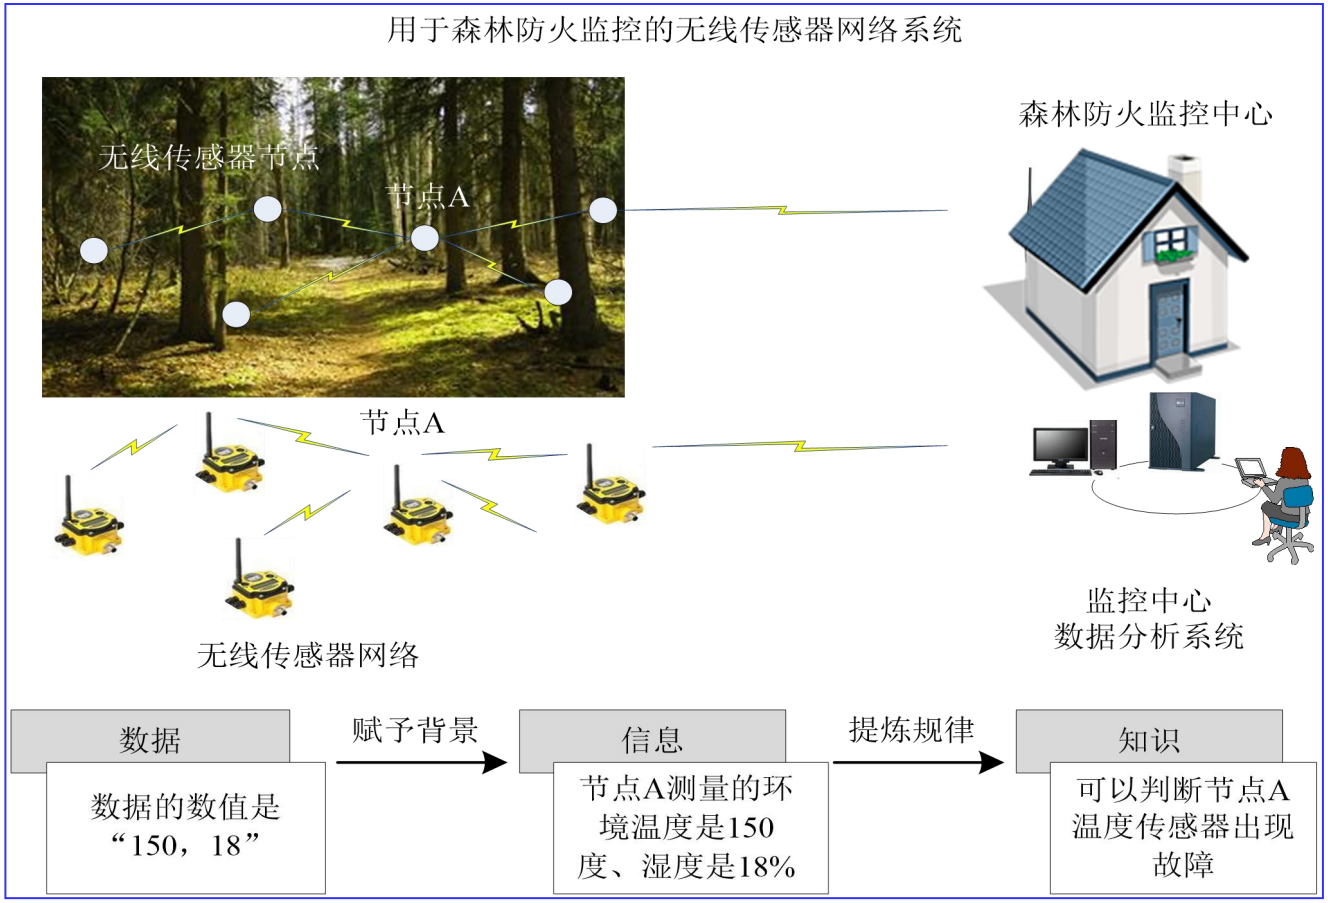

物联网智能数据处理技术的基本概念
物联网数据的特点
物联网中的数据、信息与知识
物联网数据处理关键技术
物联网与云计算
云计算产生的背景
云计算的分类
云计算主要技术特征
云计算在物联网中的应用
物联网与大数据
数据挖掘的基本概念
大数据的基本概念
大数据的特征
物联网大数据研究的特殊性

本章教学要求

- 掌握物联网数据的特征
- 理解云计算在物联网中的应用
- 理解大数据的基本概念
- 了解物联网大数据研究的特殊性

7.1 数据处理的相关概念

7.1.1 数据、信息与知识



7.1.2 智能物联网数据的特点



海量

多态



动态

关联





从无线传感器网TinyDB数据库结构中可以清晰地看到物联网数据“海量、动态、多态、关联”的特点

传感器号	查询周期	时间	湿度	光强	温度	水平加速度	垂直加速度	水平磁感应	垂直磁感应	噪声	音调	原始声音
1	1	2003-05-01	562	388	235	432	886	76	145	422	0.2	522
2	1	2003-05-01	475	233	543	655	567	65	331	655	0.5	256
3	1	2003-05-01	491	256	455	345	654	42	456	211	0.3	654
1	2	2003-05-02	586	155	654	342	432	77	470	118	0.5	422
2	2	2003-05-02	512	257	454	566	323	61	423	135	0.7	656
……	……	……	……	……	……	……	……	……	……	……	……	……

7.2 数据处理的相关技术



数据存储

数据融合

数据挖掘

智能决策

7.2.1 数据存储与数据库技术

- 关系型数据库（RDB）更适用于在线事务处理类应用，例如电子商务、酒店预订、银行业务等。流行的关系型数据库主要有Oracle、MySQL、SQL Server、PostgreSQL等。关系型数据库擅长处理表之间需要复杂查询的事务数据
- 数据仓库（DWH）更适合在线分析处理类应用。数据仓库提供对海量结构化数据的快速聚合功能。传统的基于行的数据仓库方案主要有Netezza、Teradata、Greenplum等。现代的数据仓库方案使用列式存储技术来提升查询性能与I/O效率，例如Amazon Redshift、Snowflake、Google Big Query等

NoSQL数据库技术

- NoSQL是各种非关系型数据库的统称，用于解决传统关系型数据库性能与扩展问题。NoSQL没有明确的结构连接不同表中的数据。NoSQL支持多种数据模型，包括列式、键值、搜索、文档、图模型等
- 文档数据库：用于存储、管理与查询面向文档的数据，以及半结构化数据（例如JSON、XML等格式）。文档数据库主要有MongoDB、CloudKit、CouchDB等
- 图数据库：用于存储大量复杂、互连、低结构化的图数据，例如社交网络、推荐系统等应用场景。图可以建立在关系型或非关系型数据库上。图数据库主要有Neo4J、OrientDB、InfoGrid、GraphDB等

非结构化数据存储技术

- Hadoop采用主节点与子节点模式，数据分布在多个子节点，主节点协调执行数据查询。依托大规模并行处理技术，Hadoop支持快速查询各种类型数据，包括结构化数据与非结构化数据
- 在创建Hadoop集群时，每个子节点都附带一个磁盘存储块，称为Hadoop分布式文件系统（HDFS）。Hadoop支持常见的数据查询框架，包括Hive、Ping、Spark等。如果用户使用HDFS存储数据，则存储与计算将耦合在一起

面向物联网的数据存储技术

- 在物联网数据类型中，多数属于非结构化数据与半结构化数据，同时也包含少量的结构化数据。数据存储在充分利用物联网数据方面扮演重要角色
- 为物联网应用系统选择数据存储技术，需要注意的因素：数据库大小与规模、处理海量数据的有效性、异构性与数据集成、流程建模与事务处理、时间序列聚合与归档、查询语言及效率，以及可移植性等
- 适合物联网应用系统的数据库主要有：InfluxDB、MangoDB、SQLite、RethinkDB、Cassandra等

7.2.2 数据融合技术

- 数据融合是指运用计算机相关技术，按特定规则对多个数据源（例如传感器）收集数据进行融合操作，从而获得对监测对象状态与特征估计，以生成更完整、精确、满足用户需求的信息。与通过单一数据源收集的信息相比，通过数据融合操作能获得更可靠的信息
- 从不同的角度出发，数据融合有不同的分类方式。按照执行融合操作的层次，数据融合可以分为以下三类：数据级融合、特征级融合与决策级融合。数据级融合是一种在低层执行的融合处理，融合对象是由多个数据源（例如传感器）采集的原始数据。特征级融合是一种在中间层执行的融合处理，融合对象是由多个数据源（例如传感器）数据提取的特征信息。决策级融合是一种在高层执行的融合处理，融合对象是由多个数据源（例如传感器）的数据获得的决策信息

7.2.3 数据分析与数据挖掘技术

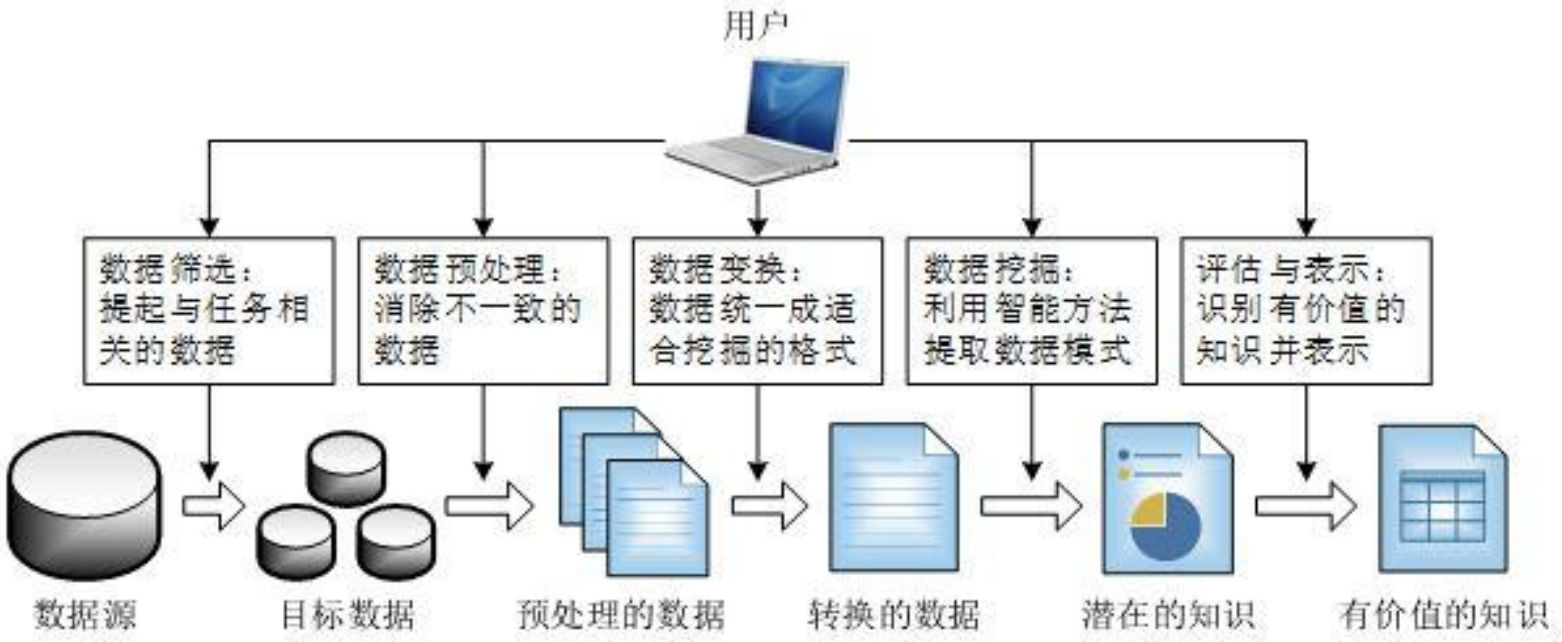
- 数据分析（Data Analysis）是利用适当的统计分析方法对收集到的海量数据进行分析，从中提取有用的信息并形成结论的处理过程。数据分析的目标是将信息从大量看似杂乱无章的数据中提炼出来，并借此总结出研究对象的内在规律
- 数据分析的操作对象是各种数据，它涵盖了数值、文字、音频、视频等表现形式。数据分析的原理是利用各种统计方法，既包括描述性统计等简单方法，又包括推断性统计、预测性统计等高级方法

数据挖掘的概念

- 数据挖掘（Data Mining）是从海量数据中揭示出隐藏的、未知的、具有潜在价值的信息的处理过程
- 随着互联网、移动互联网与物联网的快速发展，各类应用产生的数据量级在快速增长。这些海量数据之间的关系错综复杂，常规处理方法已难以适应数据处理需求，数据挖掘技术在这种背景下产生
- 数据挖掘是基于人工智能、机器学习、模式识别、统计学、数据库、可视化技术等，能够自动对数据进行分析、归纳及推理，并从中挖掘出潜在的价值模式，帮助管理者更好地做出决策

数据挖掘的概念

- 数据挖掘主要实现两个功能：通过描述性分析，做到“针对过去、揭示规律”；通过预测性分析，做到“面向未来、预测趋势”



数据挖掘的相关算法

- 根据是否需要指导进行分类，数据挖掘可以分为两类：有指导的数据挖掘与无指导的数据挖掘
- 有指导的数据挖掘又称为监督学习，它是利用原有的数据建立一个模型，该模型最终是有一个属性值，它可能是离散型变量，也可能是连续型变量。有指导的数据挖掘可分为两类：分类（离散型变量）与预测（连续型变量）
- 无指导的数据挖掘又称为无监督学习，在原有数据的所有属性中寻找一种关系，其最终输出结果没有属性值。无指导的数据挖掘可分为两类：聚类与关联规则

7.3 云计算技术与应用
7.2.1 云计算技术发展背景

- 1961年，John McCarthy就曾经预言：未来的计算资源能够像公共设施（例如水、电）一样使用
- 此后的几十年，出现过分布式计算、集群计算、网格计算、效用计算、服务计算等概念。云计算（Cloud Computing）在这些技术的基础上发展
- 2006年8月，Google公司在搜索引擎大会上首次提出了云计算的概念
- 云计算引发了软件开发部署模式的创新，成为承载各类应用的关键基础设施，为大数据、物联网、人工智能等新兴领域的发展提供了支撑聚类与关联规则

7.3.2 云计算的基本概念



按需服务—根据用户是实际计算量与数据存储量，自动分配CPU的数量与存储空间的大小，避免服务质量下降与资源浪费



资源池化—利用虚拟化技术，根据需求定制用户使用的计算与存储资源，计算与存储资源管理对用户是透明的



服务可计费—“云”可以监控用户的计算、存储资源的使用量，并根据资源的使用“量”进行计费



泛在接入—用户的各种终端设备，如PC机、笔记本计算机、智能手机和移动终端设备，都可以作为云终端，随时随地访问“云”

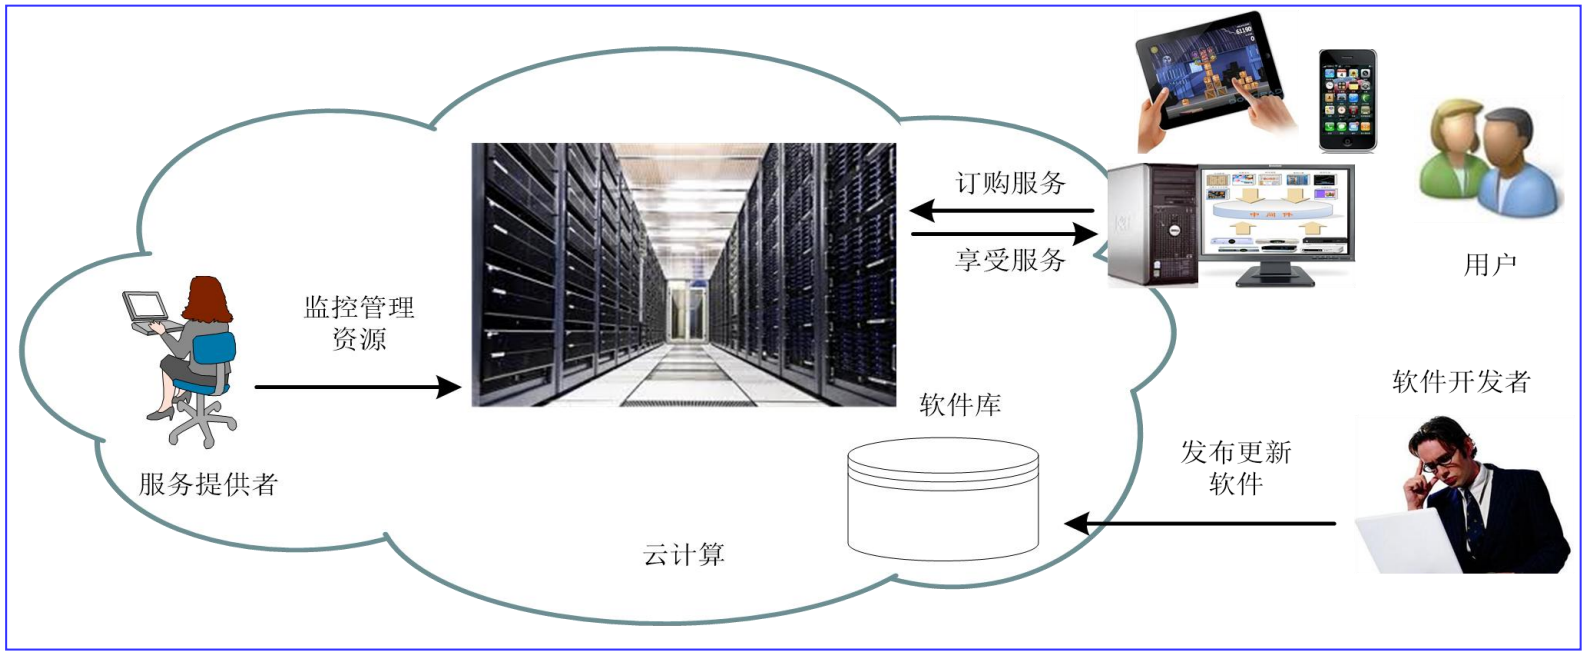


高可靠性—“云”采用数据多副本备份冗余，计算节点可替换等方法，提高云计算系统的可靠性



快速部署—云计算不针对某一些特定的应用，用户可以方便地开发各种应用软件，组建自己的应用系统，快速部署业务

云计算工作模式



云计算是一种计算模式，它是将计算与存储资源、软件与应用作为服务，通过网络提供给用户

7.3.3 云计算服务模式



IaaS：基础设施即服务，只涉及到租用硬件，是一种最基础的服务



PaaS：平台即服务，已经从硬件的基础上，租用一个特定的操作系统与应用程序，来自己进行应用软件的开发



SaaS：软件即服务，在云平台提供的定制软件上，直接部署自己的应用系统

7.3.4 云计算部署模式



公有云（public cloud）是向整个社会提供共享资源服务的云平台。“云”中的资源开放给全社会或某个大型行业使用，用户通过互联网按需付费使用“云”中的资源



私有云（private cloud）是由某个组织或机构自行组建、运行与管理，内部员工通过内部网或VPN访问的云平台

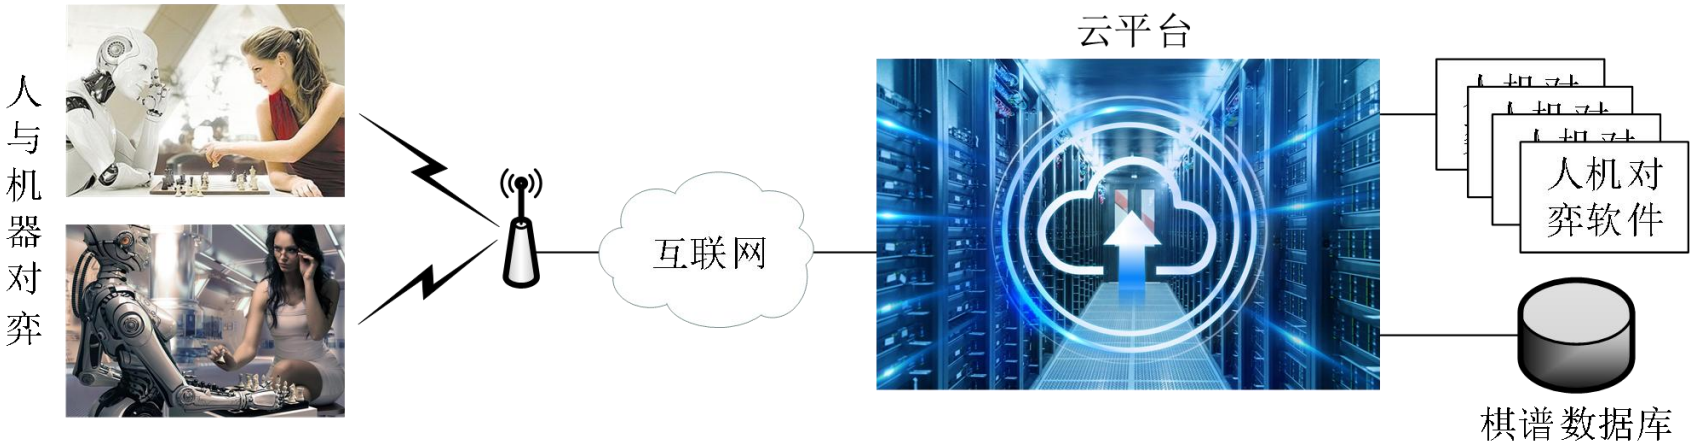


社区云（community cloud）具有公有云与私有云的双重特征。社区云与私有云的相似点：对社区云的访问受到一定的限制。社区云与公有云的相似点：社区云的资源专门提供给特定单位的内部用户使用



混合云（hybrid cloud）由公共云、私有云、社区云中的至少两种构成，其中每个云平台都是独立运行，通过标准接口或专用技术，实现不同云平台之间的平滑衔接

7.3.5 云计算的应用



用户的对手并不是与机器人，而是“隐藏”在“云”中的“虚拟”国际象棋大师

7.4 大数据技术与应用
7.4.1 大数据发展背景

- Google工程师将美国用户最频繁检索的关键字，例如“哪些是治疗咳嗽与发热的药物”，与美国疾控中心从2003至2008年季节性流感传播数据进行比较。为了找出特定关键字的使用频率与流感传播在时间、空间上的联系，总共处理了4.5亿个数学模型。研究人员选择了45个关键字与相应的数学模型进行分析，计算结果与2007年、2008年美国疾控中心公布的流感病例数据对比，相关度高达97%
- 基于大数据的分析结果能判断某个地区可能患上流感的人数。这种预测更加及时，不像疾控中心在流感爆发之后一至两周才能做出判断

7.4.2 大数据基本概念

- 大数据并没有一个非常准确的定义。对于多大的数据属于大数据，不同的学科、行业有不同的理解。例如，大数据是大到难以采用传统方法进行处理的数据集；大数据是大小超过标准数据库工具软件能够收集、存储、管理与分析的数据集
- “大数据”人为的主观定义将随着技术发展而变化，同时不同行业对大数据的“量”的衡量标准也会不同。目前，不同行业比较一致的看法是数据量在几百TB到几十PB的数据集都可以称为“大数据”

大数据研究的价值

2007年图灵奖获得者吉姆·格雷指出：科学研究将从实验科学、理论科学、计算科学，发展到数据科学；“数据密集型科学发现”将成为科学研究的第四范式；科学研究将从实验科学、理论科学、计算科学发展到目前兴起的数据科学

大数据对世界经济、自然科学、社会科学的发展将会产生重大和深远的影响；物联网的大数据应用是国家大数据战略的重要组成部分，结合物联网应用的大数据研究必将成为物联网研究的重要内容

大数据的“5V”特征



大体量（Volume）：数据量达到数百TB到数百PB，甚至是EB的规模



多样性（Variety）：数据为各种格式与各种类型



时效性（Velocity）：数据需要在一定的时间限度下得到及时处理



准确性（Veracity）：处理结果要保证一定的准确性



大价值（Value）：分析挖掘的结果可以带来重大的经济效益与社会效益

7.4.3 大数据技术发展

单位	英文标识	单位标识	大小	含意与例子
位	bit	b	0或1	计算机处理数据的二进制数
字节	byte	B	8位	计算机存储数据的基本物理单元，存储一个英文字母用1个字节表示，一个汉字用2个字节表示
千字节	KiloByte	KB	1024字节或2^{10}个字节	一张纸上的文字约为5KB个字节
兆字节	MegaByte	MB	2^{20}个字节	一个普通的MP3格式的歌曲约为4MB
吉字节	GigaByte	GB	2^{30}个字节	一部电影大约是1GB
太字节	TeraByte	TB	2^{40}个字节	美国国会图书馆所有书籍的信息量约为15TB，截至2011年底其网络备份数据量为280TB，今后每一个月以5TB的速度增长
拍字节	PetaByte	PB	2^{50}个字节	NASA EOS对地观测系统3年观测的数据量约为1PB
艾字节	ExaByte	EB	2^{60}个字节	相当于中国13亿人每人一本500页书的数据量的总和
皆字节	ZetaByte	ZB	2^{70}个字节	截至2010年人类拥有的信息量的总和约为1.2ZB
佑字节	YottaByte	YB	2^{80}个字节	超出想象 1YB=1024ZB=1 208 925 819 614 629 174 706 176 B
诺字节	NonaByte	NB	2^{90}个字节	超出想象
刀字节	DoggaByte	DB	2^{100}个字节	超出想象

7.4.4 大数据研究的共性问题



可视化分析—物联网大数据分析的可视化能够以非常直观的形式呈现给物联网用户，更容易帮助不同行业的物联网用户从中提取有价值的知识，帮助科学决策



数据挖掘算法—物联网行业应用关系国计民生与生命安全，对数据挖掘结果的时效性、可靠性与可信性要求很高，必须由大数据专家与行业专家合作研究数据挖掘算法



预测性分析能力—对于物联网应用预测性分析十分重要，需要组织行业专家、物联网专家与大数据专家相结合的研究队伍，研究适应不同行业物联网大数据的预测模型与算法



语义引擎—物联网需要一套新的理论与方法来实现对地理位置分布的各种数据资源进行规范和灵活地组织，方便用户通过关键词、标签关键词或其他输入语义的搜索，提高主动获取知识的能力



数据质量与数据管理—不同传感器感知的原始数据的汇聚，多维数据融合、多用户协同感知与数据质量管理，使得处理之后的结果更能够高精度地反映真实面貌，是物联网大数据研究的重点

7.4.5 智能物联网大数据研究的个性问题



异构性与多样性—物联网的数据来自不同的行业、不同的应用、不同的感知手段，有人与人、人与物、物与物、机器与人、机器与物、机器与机器等各种数据，这些数据可以进一步分为：状态数据、位置数据、个性化数据、行为数据与反馈数据，数据具有明显的异构性与多样性



实时性、突发性与颗粒性—物联网感知数据是系统控制命令与策略制定的基础，对物联网数据处理时间要求很高；同时，事件发生往往很突然和超出预判，事先无法考虑周全，物联网感知设备获得的数据很容易出现不全面和噪声干扰，物联网大数据的研究需要注意到数据实时性、突发性与颗粒性的特点



非结构化与隐私性—物联网应用系统中存在着大量图像、视频、语音、超媒体等非结构化数据，增加了数据处理的难度。物联网应用系统的数据中隐含有大量企业重要的商业秘密与个人隐私信息，数据处理中的信息安全与隐私保护难度大

谢谢！